Домашнее задание 2.1
Сборка таблицы SCD2

Курс Технологии хранения данных DWH

Постройте таблицу истории изменений пользователей по модели SCD Type 2. Исходная таблица размещена в S3; имя таблицы и параметры доступа выдаёт преподаватель.

1 Исходная таблица

Поле	Тип	Описание
event_time	timestamp	Дата и время события
user_id	uint32	Идентификатор пользователя
user_fio	string	Имя и фамилия латиницей
user_email	string	Электронная почта
user_login	string	Никнейм

Каждая строка содержит полное состояние профиля на момент события. Для одного пользователя атрибуты меняются редко, поэтому повторные события могут содержать те же значения.

2 Задачи

1 Поднимите в Docker S3 (предпочтительнее RustFS, так как он проще всего) и Spark + Jupitet (docker-compose со Spark и Jupitet уже встречался ранее на курсе)

2 Загрузите данные в S3, предварительно нагенерировав себе данных (случайное число от 5 к строк до 7к строк) при помощи скрипта во вложении к ДЗ, пример команды для генерации прикладываем ниже:

```
python3 generate_event_log.py --rows 100 --output-dir ./event_log --seed 42
```

3 Подготовьте и отправьте на ревью скрипт сборки SCD2 таблицы из исходной таблицы в S3. Результат сохраните в целевую таблицу в S3.

4 Посчитайте количество строк в полученной SCD2 таблице и приложите запрос подсчёта и результат.

5 Подготовьте параметризованный запрос, который находит активный user_login пользователя X на дату и время Y.

3 Целевая таблица

Поле	Тип	Правило
user_id	uint32	Идентификатор пользователя
user_fio	string	ФИО в данной версии
user_email	string	Почта в данной версии
user_login	string	Никнейм в данной версии
valid_from	timestamp	Начало действия версии
valid_to	timestamp nullable	Начало следующей версии или NULL
is_current	boolean	Признак актуальной версии

4 Правила сборки

- События каждого user_id необходимо упорядочить по event_time.
- Новая версия создаётся только при изменении user_fio, user_email или user_login.
- Интервал версии полуоткрытый: [valid_from, valid_to).
- У актуальной версии valid_to равен NULL, а is_current равен true.
- У каждого пользователя должна быть ровно одна актуальная версия; интервалы не должны пересекаться.
- Повторный запуск на тех же данных должен давать тот же результат без дублей.

5 Результат

На проверку передаются скрипт сборки, количество строк с запросом подсчёта и запрос поиска никнейма по параметрам X и Y. Для даты до первого события пользователя запрос должен возвращать пустой результат.

6 Оценивание

Критерий	Балл за выполнение критерия
Развернуто окружение с S3, Spark, Jupiter, приложен используемый docker-compose	1
Корректная история и интервалы	2
Воспроизводимая сборка без дублей	1
Подсчёт строк и запрос по X и Y	1